

LAPORAN
UJIAN AKHIR SEMESTER - CAPSTONE PROJECT

Mata Kuliah Pembelajaran Mesin - Semester Genap 2025/2026

**AI-Powered Smart Home Device Control Menggunakan Klasifikasi Gestur
Tangan Real-Time Berbasis Landmark MediaPipe, Random Forest, dan
Support Vector Machine**



Disusun oleh:
Muhammad Zakaria Putranto
NIM: A11.2024.16031
Kelompok: A11.4405

FAKULTAS ILMU KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA
UNIVERSITAS DIAN NUSWANTORO
SEMARANG
TAHUN AJARAN 2025/2026

BAB 1 - PENDAHULUAN

1.1 Latar Belakang Masalah

Sistem otomasi rumah pintar (Smart Home) berkembang pesat seiring kemajuan teknologi Internet of Things (IoT) dan Kecerdasan Buatan. Salah satu fitur utama smart home adalah pengendalian pencahayaan (saklar lampu). Metode kendali konvensional yang mengandalkan aplikasi remote atau tombol fisik memiliki keterbatasan kepraktisan, misalnya saat tangan pengguna kotor, basah, atau sedang memegang barang.

Solusi berbasis Computer Vision menawarkan alternatif kendali menggunakan gestur tangan (hand gestures). Namun, pendekatan konvensional yang memproses citra mentah secara langsung menggunakan arsitektur Deep Learning seperti Convolutional Neural Network (CNN) membutuhkan daya komputasi besar (GPU) sehingga kurang praktis untuk perangkat rumah pintar berspesifikasi rendah.

Proyek ini awalnya dirancang untuk deteksi chord gitar berbasis gestur tangan. Namun, evaluasi teknis pada tahap awal menemukan tingkat oklusi (penutupan jari) yang tinggi pada koordinat landmark tangan, sehingga fokus proyek dialihkan ke pengenalan gestur untuk kendali lampu smart home yang memiliki struktur gestur lebih tegas dan minim oklusi, sehingga meningkatkan reliabilitas sistem.

Untuk menyelesaikan permasalahan efisiensi komputasi tersebut, penelitian ini menerapkan ekstraksi fitur spasial koordinat landmark tangan menggunakan kerangka kerja MediaPipe Hands sebelum melakukan klasifikasi. Pendekatan ini mengubah aliran video beresolusi tinggi menjadi data tabular sederhana yang hanya terdiri dari 21 titik sendi tangan dengan koordinat X, Y, Z (63 fitur numerik), sehingga model Machine Learning klasik yang ringan seperti Random Forest dan Support Vector Machine (SVM) dapat digunakan untuk klasifikasi secara akurat dan real-time pada CPU biasa.

1.2 Rumusan Masalah

- Bagaimana tingkat akurasi dan karakteristik algoritma Random Forest dibandingkan dengan Support Vector Machine (SVM) Linear dalam mengklasifikasikan gestur tangan berbasis data tabular koordinat landmark MediaPipe?
- Bagaimana mengatasi fluktuasi prediksi (flickering) yang muncul pada transisi antar gestur yang memiliki kemiripan koordinat?
- Bagaimana menginterpretasikan keputusan model machine learning yang bersifat black-box menggunakan metode Explainable AI (SHAP) agar diketahui koordinat jari mana yang paling berpengaruh terhadap prediksi?
- Bagaimana mengimplementasikan model terbaik ke dalam aplikasi web interaktif yang dapat mendemonstrasikan simulasi saklar lampu smart home secara real-time?

1.3 Mengapa Machine Learning Diperlukan

Pendekatan hard-coding berbasis logika if-else (misalnya membandingkan jarak antar ujung jari) terbukti sangat rentan terhadap perbedaan ukuran tangan, sudut kemiringan, dan jarak pengguna terhadap kamera. Machine Learning memungkinkan sistem mempelajari pola koordinat secara fleksibel dari data, sehingga lebih adaptif terhadap variasi antar pengguna dibandingkan aturan manual yang kaku.

1.4 Tujuan Penelitian

- Membangun model machine learning yang mampu mengklasifikasikan gestur tangan dari koordinat landmark MediaPipe dengan akurasi pengujian setinggi mungkin.
- Membandingkan karakteristik Random Forest dan SVM Linear dari sisi akurasi, ukuran model, dan waktu pelatihan/inferensi.
- Menganalisis kontribusi koordinat sendi jari terhadap keputusan klasifikasi menggunakan visualisasi SHAP.
- Men-deploy model terbaik ke dalam aplikasi Streamlit (dashboard analitis) dan Flask (simulasi saklar smart home real-time).

1.5 Dataset dan Sumber Data

Dataset yang digunakan bersumber dari repositori publik GitHub (Raoina, 2023) berupa koordinat hasil ekstraksi MediaPipe Hands, terdiri dari 25.675 sampel yang tersebar pada 18 kelas gestur tangan (di antaranya palm, fist, peace, four, like, dislike, ok, two_up_inverted, dan lainnya). Setiap sampel memiliki 63 fitur numerik bertipe float64 (21 titik landmark x 3 koordinat X, Y, Z) sebagai input, dan satu kolom label kategorikal sebagai target. Statistik deskriptif awal menunjukkan tidak ditemukan missing values pada dataset karena kegagalan deteksi tangan oleh MediaPipe tidak disimpan sejak proses akuisisi data.

BAB 2 - METODOLOGI PENELITIAN

2.1 Alur Kerja (Pipeline) Machine Learning

Alur kerja penelitian dirancang secara end-to-end sebagai berikut:

- Akuisisi data koordinat tangan dari dataset publik hasil ekstraksi MediaPipe Hands.
- Data cleaning: pemeriksaan missing values, duplikat, dan normalisasi penulisan label (`data_preprocessing.py`).
- Exploratory Data Analysis (EDA): distribusi kelas, korelasi antar koordinat, dan visualisasi pola landmark (`01_hand_gesture_eda.ipynb`).
- Pembagian data latih dan uji dengan proporsi 80:20 menggunakan stratified split.
- Pelatihan dua model: Random Forest Classifier dan Support Vector Machine kernel Linear (`02_modeling.ipynb`, `train_and_save_all.py`).
- Evaluasi komparatif menggunakan Accuracy, Precision, Recall, F1-Score, Confusion Matrix, dan ROC-AUC.
- Interpretasi model menggunakan SHAP (`03_interpretation.ipynb`).
- Deployment model terbaik ke aplikasi Streamlit (dashboard analitis) dan Flask (simulasi real-time smart home).

2.2 Preprocessing Data

Tahap preprocessing pada `src/data_preprocessing.py` melakukan tiga hal utama: (1) pemeriksaan dan penghapusan missing values, (2) pemeriksaan dan penghapusan data duplikat, serta (3) normalisasi konsistensi penulisan label (strip spasi dan penyeragaman huruf kecil). Hasil pembersihan disimpan pada `data/processed/hand_landmarks_data_clean.csv`.

Untuk efisiensi waktu pelatihan pada tahap eksperimen, proses training pada `train_and_save_all.py` melakukan subsampling maksimum 300 sampel per kelas gestur sebelum pembagian data latih dan uji. Pendekatan ini mempercepat proses eksperimen dan menjaga keseimbangan jumlah sampel antar kelas (class balance), namun sebagai konsekuensinya jumlah data latih yang benar-benar digunakan pada model final menjadi lebih sedikit dibandingkan total dataset yang tersedia (25.675 sampel). Hal ini didokumentasikan secara transparan sebagai trade-off antara kecepatan eksperimen dan volume data latih.

2.3 Pemilihan dan Pelatihan Algoritma

2.3.1 Random Forest Classifier

Random Forest merupakan algoritma Ensemble Learning yang membangun banyak Decision Tree secara paralel menggunakan teknik bagging (bootstrap aggregating). Setiap pohon dilatih pada subset data yang berbeda, dan prediksi akhir ditentukan melalui voting mayoritas. Karakteristik ini membuat Random Forest tangguh terhadap noise pada koordinat tangan yang sedikit bergetar, serta lebih tahan overfitting dibandingkan satu Decision Tree tunggal. Pada implementasi ini, parameter `n_estimators=100` dan `max_depth=15` dipilih berdasarkan uji coba manual untuk menyeimbangkan akurasi dengan ukuran file model (mengurangi ukuran dari sekitar 307 MB menjadi sekitar 30 MB), bukan melalui pencarian hyperparameter otomatis seperti Grid Search.

2.3.2 Support Vector Machine (SVM) Kernel Linear

SVM bekerja dengan mencari hyperplane pemisah yang memaksimalkan margin antar kelas data pada ruang berdimensi tinggi. Kernel Linear dipilih karena koordinat landmark tangan MediaPipe cenderung linearly separable, serta SVM dikenal efektif ketika jumlah fitur (63 dimensi) sebanding dengan jumlah sampel. Parameter yang digunakan adalah $C=1.0$, $probability=True$ (untuk mendukung confidence threshold), $max_iter=2000$, dan $tol=1e-3$ untuk mempercepat konvergensi.

Perlu dicatat sebagai keterbatasan metodologis: kedua model saat ini dilatih menggunakan kombinasi parameter yang ditentukan berdasarkan pengalaman/uji coba manual, bukan melalui teknik pencarian hyperparameter otomatis seperti Grid Search, Random Search, atau Bayesian Optimization (Optuna) sebagaimana disarankan pada ketentuan proyek. Hal ini menjadi salah satu rekomendasi pengembangan pada Bab 4.

2.4 Strategi Pembagian Data

Pembagian data menggunakan fungsi `train_test_split` dari Scikit-Learn dengan proporsi 80% data latih dan 20% data uji, parameter `random_state=42` untuk reproduktifitas, serta `stratify=y_encoded` agar proporsi 18 kelas gestur tetap seimbang pada kedua subset data.

2.5 Metrik Evaluasi

- Accuracy Score - ketepatan prediksi secara keseluruhan.
- Precision, Recall, F1-Score (macro-average) - performa per kelas gestur, penting karena terdapat 18 kelas.
- Confusion Matrix - untuk mengidentifikasi pasangan gestur yang paling sering tertukar.
- ROC-AUC (micro-average) - kemampuan model memisahkan kelas secara keseluruhan.

2.6 Rancangan Deployment

Model terbaik disebarkan (deploy) ke dua antarmuka: (1) aplikasi Flask (`app/app.py`) yang menjalankan simulasi saklar lampu smart home tiga ruangan (Dapur, Ruang Tamu, Kamar) secara real-time menggunakan video feed webcam, dan (2) aplikasi Streamlit (`app/streamlit_app.py`) yang berfungsi sebagai dashboard analitis berisi lima menu wajib: Dashboard EDA, Demo Prediksi Saklar, Evaluasi Model, Interpretasi Model (SHAP), dan Dokumentasi Proyek.

BAB 3 - HASIL DAN ANALISIS

3.1 Perbandingan Performa Model


Berdasarkan pengujian terhadap data uji (20% dari data hasil subsampling), performa kedua model dirangkum pada tabel berikut:

Metrik Evaluasi	Random Forest	SVM Linear (Terbaik)
Akurasi Pengujian (Test)	82.03%	93.55%
Akurasi Pelatihan (Train)	98.50%	95.12%
Rata-rata Precision (Macro)	0.82	0.94
Rata-rata Recall (Macro)	0.81	0.93
Rata-rata F1-Score (Macro)	0.81	0.93
ROC-AUC (Micro-average)	0.9782	0.9945
Waktu Pelatihan	~360 detik	~1.920 detik
Ukuran File Model (.pkl)	~307 MB (sebelum dibatasi depth) / ~30 MB (final)	~8.4 MB

3.2 Analisis Kritis Perbandingan Model


SVM Linear mencapai akurasi pengujian tertinggi sebesar 93,55%, mengungguli Random Forest yang memperoleh 82,03%. Kesenjangan antara akurasi pelatihan (98,50%) dan pengujian (82,03%) pada Random Forest mengindikasikan gejala overfitting ringan, kemungkinan karena pembagian pohon keputusan yang kurang optimal untuk data koordinat spasial yang bersifat kontinu dan saling berkorelasi tinggi antar titik landmark (multikolinieritas). Sebaliknya, SVM Linear menunjukkan selisih akurasi latih-uji yang lebih kecil (95,12% vs 93,55%), mengindikasikan generalisasi yang lebih baik. Dari sisi efisiensi, SVM juga menghasilkan ukuran file model yang jauh lebih kecil (~8,4 MB berbanding ~30 MB) meskipun waktu pelatihannya lebih lama.

3.3 Confusion Matrix dan Kurva ROC



Gambar 3.1 Confusion Matrix model SVM (model terbaik) pada data uji

Confusion Matrix pada Gambar 3.1 menunjukkan konsentrasi nilai yang tinggi di sepanjang diagonal utama, menandakan mayoritas sampel diklasifikasikan dengan tepat sesuai label aslinya. Kesalahan klasifikasi yang tersisa umumnya terjadi antar gestur dengan pola koordinat landmark yang berdekatan secara geometris, misalnya antar variasi gestur jari yang terangkat sebagian.



Gambar 3.2 Perbandingan Kurva ROC (micro-average) Random Forest vs SVM

Kurva ROC pada Gambar 3.2 menunjukkan SVM Linear memiliki AUC sebesar 0,9945, sedikit lebih tinggi dibandingkan Random Forest (0,9782). Kurva SVM lebih mendekati sudut kiri atas, mengonfirmasi tingkat false positive yang lebih rendah.

ml-experiment

02_modeling.ipynb U

notebooks > 02_modeling.ipynb > M1 Bab 3: Pemodelan & Evaluasi > import os

Generate + Code + Markdown Run All Restart Clear All Outputs Jupyter Variables Outline


Laporan Klasifikasi Detail Model Terbaik:

	precision	recall	f1-score	support
call	0.91	0.90	0.90	301
dislike	0.91	0.92	0.92	259
fist	0.88	0.87	0.87	189
four	0.73	0.71	0.72	327
like	0.94	0.92	0.93	287
mute	0.88	0.93	0.90	217
ok	0.97	0.95	0.96	318
one	0.96	0.88	0.92	253
palm	0.72	0.79	0.75	330
peace	0.55	0.54	0.55	288
peace_inverted	0.69	0.78	0.73	299
rock	0.96	0.97	0.96	292
stop	0.80	0.85	0.83	296
stop_inverted	0.90	0.97	0.93	314
three	0.93	0.88	0.90	291
three2	0.78	0.81	0.80	331
two_up	0.61	0.55	0.58	269
two_up_inverted	0.69	0.58	0.63	274
accuracy			0.82	5135
macro avg	0.82	0.82	0.82	5135
weighted avg	0.82	0.82	0.82	5135

Spaces: 4

Gambar 3.3 Classification Report per kelas gestur (Precision, Recall, F1-Score)

3.4 Interpretasi Model dengan SHAP



Gambar 3.4 SHAP Feature Importance untuk gestur 'peace' (dihitung dari Random Forest)

Analisis SHAP pada Gambar 3.4 dihitung menggunakan TreeExplainer terhadap model Random Forest (bukan model SVM yang menjadi model final untuk deployment), karena TreeExplainer memberikan komputasi yang jauh lebih cepat dan stabil dibandingkan KernelExplainer yang diperlukan untuk model non-tree seperti SVM.

Hasilnya menunjukkan bahwa koordinat sumbu Y pada ujung jari (seperti y8 untuk jari telunjuk dan y12 untuk jari tengah) memiliki kontribusi (SHAP value) tertinggi terhadap prediksi gestur peace, karena posisi tegak/tekuk jari secara visual paling banyak diwakili oleh perubahan pada sumbu vertikal. Sebagai catatan metodologis, karena interpretasi ini berbasis Random Forest sedangkan model yang benar-benar dipakai pada aplikasi adalah SVM Linear, pola kepentingan fitur di atas bersifat indikatif dan sebaiknya dikonfirmasi ulang dengan koefisien bobot (coefficient) SVM Linear pada pengembangan berikutnya.

3.5 Implementasi Deployment


Model terbaik (SVM Linear) diimplementasikan pada dua aplikasi:

- Aplikasi Flask (app/app.py): menjalankan simulasi saklar lampu tiga ruangan (Dapur, Ruang Tamu, Kamar) menggunakan video feed webcam secara real-time.
- Aplikasi Streamlit (app/streamlit_app.py): dashboard analitis dengan lima menu - Dashboard EDA, Demo Prediksi Saklar, Evaluasi Model, Interpretasi Model (SHAP), dan Dokumentasi Proyek.




Gambar 3.5 Tampilan awal dashboard simulasi smart home sebelum tangan terdeteksi


Pengujian fungsional pada aplikasi Flask menunjukkan sistem berhasil memetakan empat gestur berbeda ke tiga ruangan secara real-time, sebagaimana didokumentasikan pada rangkaian tangkapan layar berikut:




Gambar 3.6 Gestur 'peace' terdeteksi -> lampu Dapur menyala (oranye)



Gambar 3.7 Gestur 'four' terdeteksi -> lampu Ruang Tamu menyala (kuning)



Gambar 3.8 Gestur 'two_up_inverted' terdeteksi -> lampu Kamar menyala (cyan)



Gambar 3.9 Gestur 'fist' terdeteksi -> seluruh lampu dalam kondisi mati (status default/off)


Keempat tangkapan layar di atas menunjukkan bahwa pipeline end-to-end (kamera -> ekstraksi landmark MediaPipe -> klasifikasi SVM -> pemetaan aksi saklar) berfungsi sebagaimana dirancang ketika tangan berhasil terdeteksi dengan orientasi yang memadai.

3.6 Pengujian Lapangan dan Analisis Keterbatasan Model

Selain evaluasi statistik pada data uji, dilakukan pula pengujian langsung menggunakan best_model (SVM Linear) melalui webcam. Pengujian lapangan ini mengungkap dua jenis keterbatasan yang berbeda akar penyebabnya, yang perlu dibedakan secara eksplisit agar tidak disalahartikan sebagai satu masalah yang sama.

3.6.1 Temuan A - Kegagalan Ekstraksi Landmark MediaPipe ("Tidak Ada Tangan")

Pada sebagian pengujian, status sistem menampilkan "TIDAK ADA TANGAN" meskipun tangan pengguna sebenarnya masih berada di dalam bidang pandang kamera. Perlu ditegaskan bahwa kondisi ini terjadi ketika model sudah aktif dan sepenuhnya dimuat (bukan pada tahap awal sebelum model tersedia). Tangkapan layar berikut menunjukkan kasus tersebut:



Gambar 3.10 Status 'TIDAK ADA TANGAN' meskipun model sudah aktif dan tangan berada di dalam frame

Pada gambar tersebut, posisi tangan berada menyamping terhadap kamera - jari-jari tidak terentang menghadap lensa, sehingga bentuk yang tertangkap kamera hanya berupa siluet tipis menyerupai sisi pergelangan tangan, bukan pola telapak tangan yang lengkap. Berdasarkan penelusuran kode `app/app.py`, deteksi tangan menggunakan `mp_hands.Hands(min_detection_confidence=0.7)`. Kegagalan ini terjadi pada tahap ekstraksi landmark oleh MediaPipe itu sendiri, sebelum data sempat diteruskan ke model klasifikasi (Random Forest/SVM) - dengan kata lain, model machine learning belum sempat melakukan prediksi apa pun karena variabel `results.multi_hand_landmarks` kosong. Penyebab paling mungkin adalah MediaPipe Hands dilatih mayoritas pada citra tangan yang menghadap penuh ke kamera, sehingga sudut tangan yang tidak ideal menurunkan confidence deteksi hingga di bawah ambang batas 0.7 yang ditetapkan.

- Rekomendasi teknis: menurunkan `min_detection_confidence` (misalnya ke 0,5-0,6) dan menambahkan parameter `min_tracking_confidence` secara eksplisit.
- Rekomendasi UX: menambahkan instruksi visual pada dashboard (contoh: "Hadapkan telapak tangan ke kamera") agar pengguna mengetahui sudut pengambilan yang optimal.
- Rekomendasi stabilitas: menerapkan `grace period/frame buffering`, yaitu mempertahankan status gestur terakhir selama beberapa frame sebelum benar-benar dinyatakan "Tidak Ada Tangan", agar sistem tidak terlalu sensitif terhadap perubahan sudut sesaat.

3.6.2 Temuan B - Kerancuan Klasifikasi Antar Gestur yang Mirip

- Gestur peace tetap berhasil dikenali oleh model (lihat Gambar 3.6), namun posisi tangan perlu diletakkan lebih jauh dari kamera dibandingkan pengujian sebelumnya agar prediksi tetap stabil.
- Gestur mengangkat dua jari (telunjuk dan jari tengah) secara berdekatan lebih sering diklasifikasikan sebagai palm (telapak tangan terbuka) dibandingkan sebagai gestur dua-jari yang dimaksud.

Berbeda dengan Temuan A, pada kasus ini landmark tangan berhasil diekstrak oleh MediaPipe (tangan terdeteksi), namun model klasifikasi (SVM) keliru menebak kelas gestur akibat kemiripan pola koordinat. Akar penyebabnya adalah belum diterapkannya normalisasi koordinat relatif skala-invarian pada pipeline preprocessing saat ini. Berdasarkan proposal awal (UTS), rencana normalisasi berupa `relative coordinates` terhadap titik wrist (landmark ke-0) telah dirancang, namun pada implementasi akhir, model dilatih langsung menggunakan koordinat mentah hasil ekstraksi MediaPipe tanpa penskalaan ulang terhadap ukuran/jarak tangan. Akibatnya:

- Model sensitif terhadap jarak tangan ke kamera, karena skala koordinat (magnitude X, Y, Z) berubah seiring perubahan jarak, sehingga rentang jarak optimal untuk pengujian dapat bergeser dari kondisi saat model dilatih (data drift antara dataset publik dan kondisi kamera pengguna).
- Gestur dengan jari yang dirapatkan berdekatan (seperti dua jari yang diangkat bersamaan tanpa direntangkan) menghasilkan pola koordinat yang secara geometris mendekati pola palm, sehingga rawan tertukar terutama apabila confidence probability model berada tepat di sekitar ambang batas (threshold) yang diterapkan pada mekanisme Probability Threshold untuk mencegah flickering status lampu.

Kedua temuan lapangan ini melengkapi hasil evaluasi kuantitatif pada data uji, dan menegaskan bahwa akurasi tinggi pada dataset uji (93,55%) tidak serta-merta menjamin kestabilan performa yang identik pada kondisi penggunaan nyata (real-world generalization gap). Temuan A menyoroti keterbatasan pada tahap ekstraksi landmark (MediaPipe), sedangkan Temuan B menyoroti keterbatasan pada tahap klasifikasi (SVM) - keduanya perlu ditindaklanjuti dengan rekomendasi yang berbeda pada Bab 4.

BAB 4 - KESIMPULAN DAN REKOMENDASI

4.1 Kesimpulan

- Klasifikasi gestur tangan berbasis koordinat landmark MediaPipe terbukti menjadi solusi yang efisien untuk mereduksi kompleksitas data video menjadi data tabular berdimensi rendah (63 fitur), sehingga model klasik yang ringan dapat digunakan tanpa memerlukan GPU.
- Algoritma Support Vector Machine (SVM) Kernel Linear terpilih sebagai model terbaik dengan akurasi pengujian 93,55% dan ukuran file yang ringan (~8,4 MB), mengungguli Random Forest (82,03%) yang menunjukkan indikasi overfitting.
- Analisis SHAP mengindikasikan koordinat vertikal ujung jari telunjuk (y8) dan jari tengah (y12) sebagai fitur yang paling berpengaruh terhadap gestur peace, meskipun interpretasi ini perlu dikonfirmasi lebih lanjut karena dihitung dari model Random Forest, bukan dari model SVM yang di-deploy.
- Sistem berhasil di-deploy ke dua antarmuka (Streamlit untuk analitik, Flask untuk simulasi real-time) dan terbukti berfungsi memetakan gestur peace, four, two_up_inverted, dan fist ke aksi saklar yang sesuai. Namun, pengujian lapangan mengungkap dua keterbatasan berbeda: (a) kegagalan ekstraksi landmark MediaPipe pada sudut tangan tertentu (status 'Tidak Ada Tangan'), dan (b) kerancuan klasifikasi SVM antara gestur dua-jari rapat dengan gestur palm serta sensitivitas terhadap jarak kamera.
- Proses pelatihan model saat ini menggunakan hyperparameter hasil uji coba manual, belum menggunakan teknik pencarian hyperparameter otomatis (Grid Search/Random Search/Optuna) sebagaimana diharapkan pada ketentuan proyek.

4.2 Rekomendasi Pengembangan

- Perbaikan Parameter Deteksi MediaPipe: menurunkan min_detection_confidence (misalnya ke 0,5-0,6), menambahkan min_tracking_confidence, serta menerapkan grace period/frame buffering agar status 'Tidak Ada Tangan' tidak terlalu sensitif terhadap perubahan sudut tangan sesaat (menjawab Temuan A pada Bab 3.6.1).
- Normalisasi Spasial Invarian: menerapkan relative coordinates terhadap titik wrist (x1, y1 sebagai pusat 0,0) serta membaginya dengan panjang telapak tangan, agar sistem tetap akurat meskipun posisi tangan lebih dekat/jauh dari kamera atau miring (menjawab Temuan B pada Bab 3.6.2).
- Hyperparameter Tuning Otomatis: menerapkan GridSearchCV, RandomizedSearchCV, atau Optuna pada kedua model untuk memastikan parameter yang digunakan benar-benar optimal, bukan hasil uji coba manual, sekaligus memenuhi ketentuan teknis proyek.
- Konsistensi Interpretasi Model: menghitung SHAP (menggunakan KernelExplainer atau LinearExplainer) langsung pada model SVM Linear yang menjadi model final deployment, agar interpretasi fitur selaras dengan model yang benar-benar digunakan pengguna.
- Penambahan Data dan Augmentasi: memperbanyak data latih (tidak hanya subsampling 300 sampel/kelas) serta menambah variasi jarak kamera, sudut tangan, dan intensitas cahaya, termasuk skenario malam hari, agar model lebih tangguh terhadap kondisi penggunaan nyata.
- Panduan Penggunaan (UX): menambahkan instruksi visual pada dashboard agar pengguna mengarahkan telapak tangan menghadap kamera, mengurangi kasus kegagalan deteksi landmark akibat sudut tangan yang tidak ideal.

DAFTAR PUSTAKA

- Luger, G. F. (2009). Artificial Intelligence: Structures and Strategies for Complex Problem Solving. Addison-Wesley.
- Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273-297.
- Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems (NeurIPS), 4765-4774.
- Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- Raoina. (2023). Hand Gesture Classification Dataset. GitHub Repository: <https://github.com/Raoina/Hand-Gesture-Classification>
- Lugaresi, C., et al. (2019). MediaPipe: A Framework for Building Perception Pipelines. Google Research.